

Test de Sistema Inteligentes - MUIINF

ETSINF, Universitat Politècnica de València, 14 de Junio de 2016

Apellido:

Nombre:

Cuestiones(60 minutos, sin apuntes)

Marca cada recuadro con una única opción entre las dadas.

☐ B En el marco de la máxima entropía, la función

$$p(y|x) = \frac{1}{Z(x)} \exp\left(\sum_i \lambda_i f_i(x, y)\right)$$

donde $Z(x) = \sum_y \exp(\sum_i \lambda_i f_i(x, y))$ es:

- A) la función obtenida para clasificar una vez se deriva la función a optimizar respecto a los multiplicadores de Lagrange.
- B) la función obtenida para clasificar una vez se deriva la función a optimizar respecto a las probabilidades *a posteriori* del modelo.
- C) la función a optimizar.
- D) la función obtenida para clasificar una vez se deriva la función a optimizar respecto a las restricciones.

☐ D En el marco de la máxima entropía, la expresión $\delta_i = \frac{1}{M} \log \frac{\tilde{p}(f_i)}{p_\lambda(f_i)}$

- A) se utiliza en para clasificar una muestra según la expresión $p(y|x)$
- B) se utiliza en para clasificar una muestra según la expresión $p(y, x)$
- C) se utiliza en el algoritmo de aprendizaje IIS para optimizar las características $f_i(y, x)$.
- D) se utiliza en el algoritmo de aprendizaje IIS para optimizar los valores λ asociados a las características

☐ C En el marco de la máxima entropía, la expresión $\tilde{p}(f_i) = \sum_{x,y} \tilde{p}(x, y) f_i(x, y)$ representa:

- A) el valor esperado de la distribución empírica $\tilde{p}(x, y)$ de acuerdo con la característica $f_i(x, y)$.
- B) el producto esperado de $f_i(x, y)$ y $\tilde{p}(x, y)$.
- C) el valor esperado de la característica $f_i(x, y)$ de acuerdo con la distribución empírica $\tilde{p}(x, y)$
- D) el valor normalizado de la característica $f_i(x, y)$.

☐ C En el algoritmo IIS el incremento δ_i a aplicar a cada λ_i en cada iteración es función de los valores:

- A) $\tilde{p}(f_i) = \sum_{x,y} \tilde{p}(x|y) f_i(x, y)$ y $p_\lambda(f_i) = \sum_{x,y} p_\lambda(y|x) f_i(x, y)$.
- B) $\tilde{p}(f_i) = \sum_{x,y} \tilde{p}(x|y) f_i(x, y)$ y $p_\lambda(f_i) = \sum_{x,y} \tilde{p}(x) p_\lambda(y|x) f_i(x, y)$.
- C) $\tilde{p}(f_i) = \sum_{x,y} \tilde{p}(x) \tilde{p}(y|x) f_i(x, y)$ y $p_\lambda(f_i) = \sum_{x,y} \tilde{p}(x) p_\lambda(y|x) f_i(x, y)$.
- D) $\tilde{p}(f_i) = \sum_{x,y} \tilde{p}(x, y) f_i(x, y)$ y $p_\lambda(f_i) = \sum_{x,y} \tilde{p}(x) p_\lambda(x, y) f_i(x, y)$.

☐ C Sea un problema de clasificación en cuatro clases A, B, C y D tal que la clasificación se realiza a partir de 3 características c_0, c_1 y c_2 . Se dispone de un modelo entrenado por Máxima Entropía cuyas características son del tipo:

$$f(x, y) = \begin{cases} 1 & \text{si } y = S \text{ la característica } c_j \text{ está presente en } x \\ 0 & \text{en otro caso} \end{cases}$$

donde $S \in \{A, B, C, D\}$.

Suponiendo que $\lambda_{A,c_0} = \lambda_{C,c_1} = 1, \lambda_{B,c_1} = \lambda_{D,c_2} = -1$ y el resto de valores λ son 0, indica cuál sería la clase en la que se clasificaría una muestra que tuviese las características c_1 y c_2 .

- A) En A.
- B) En B.
- C) En C.
- D) En D.

☐ A En el marco de la máxima entropía, los valores $f_i(x, y)$:

- A) Son siempre enteros.
- B) Son siempre reales.
- C) Son siempre vectores de valores reales.
- D) Nunca toman valores nulos.

- A** En la aproximación inversa a traducción estadística mediante la expresión $\hat{e} = \arg \max_e P(e)P(f|e)$
- A) $P(e)$ representa la probabilidad *a priori* de la traducción e de la cadena f y se denomina modelo de lenguaje.
 - B) $P(f|e)$ representa la probabilidad *a posteriori* de la traducción e de la cadena f y se denomina modelo de lenguaje.
 - C) $P(e)$ representa la probabilidad *a priori* del modelo de traducción.
 - D) Ninguna de las anteriores
- A** Con un modelo de lenguaje de n -gramas la probabilidad de una cadena y se aproxima como:
- A) $P(y) = P(y_1) \prod_{i=2}^{|y|} P(y_i | y_{i-n+1} \dots y_{i-1})$.
 - B) $P(y) = P(y_1) \prod_{i=2}^{|y|} P(y_i, y_{i-n+1} \dots y_{i-1})$.
 - C) $P(y) = P(y_1) \prod_{i=2}^{|y|} P(y_i | y_1 \dots y_{i-1})$.
 - D) $P(y) = P(y_1) \prod_{i=2}^{|y|} P(y_{i-n+1})$.
- C** En traducción estadística, el modelo de lenguaje
- A) Se aprende a partir de pares de entrada (e, f) , donde e es una frase en la lengua origen y f es su traducción en la lengua destino.
 - B) Se aprende a partir de cadenas en la lengua origen.
 - C) Se aprende a partir de cadenas en la lengua destino.
 - D) Se define manualmente.
- D** En traducción estadística, el problema de la búsqueda con un modelo log-lineal utiliza la siguiente expresión:
- A) $\hat{y} = \arg \max_y \sum_{k=1}^K \lambda_k h_k(x|y)$.
 - B) $\hat{y} = \arg \max_y \sum_{k=1}^K \lambda_k \log h_k(x|y)$.
 - C) $\hat{y} = \arg \max_y \sum_{k=1}^K \log h_k(x, y)$.
 - D) $\hat{y} = \arg \max_y \sum_{k=1}^K \lambda_k h_k(x, y)$.
- A** Dada la frase de referencia “éramos dos antiguos amigos” y la frase “éramos dos amigos antiguos” producida por un sistema de traducción estadística, y suponiendo que $BP = 1$, y w_n es equiprobable, el $BLEU = BP \exp \left(\sum_{n=1}^N w_n \log P_n \right)$ con precisión de n -gramas hasta $n = 2$ es:
- A) 0,50.
 - B) 0,42.
 - C) 0,61.
 - D) 0,70.
- B** El paquete de traducción estadística GIZA
- A) Permite aprender el modelo de lenguaje utilizado para traducción.
 - B) Permite aprender los modelos de alineamiento de los modelos de IBM.
 - C) Permite aprender los pesos del modelo log-lineal de traducción.
 - D) Permite aprender los modelos de alineamiento de los modelos de IBM y los pesos del modelo log-lineal de traducción.